

Learning Specialized Activation Functions for Physics informed Neural Networks

Honghui Wang¹, Lu Lu², Shiji Song¹, Gao Huang¹

Department of Automation, **Tsinghua University**, Beijing 100084, P.R. China.

Department of Chemical and Biomolecular Engineering, **University of Pennsylvania**, Philadelphia, PA 19104,
USA

Julian Sierra Salamanca
Maestría en Matemáticas Aplicadas

¿Qué son las redes neuronales informadas por la física - PINNs?

Las PINNs son una aproximación de una función que satisface una ecuación diferencial parcial arbitraria (EDP). Sea una ecuación diferencial parcial en su forma generalizada, en donde:

$$D_t^n u(\mathbf{x}, t) + \mathcal{N}[u(\mathbf{x}, t; \lambda)] = 0, \quad \mathbf{x} \in \Omega \subset \mathcal{R}^n, \quad t \in [0, T]$$

Donde $\mathcal{N}$ es el operador diferencial parcial de orden superior de las coordenadas, λ son los coeficientes del operador, D_t^n es la derivada temporal de orden superior.

A través del teorema de aproximación universal, las redes neuronales pueden aproximarse tanto como se quiera y se pueda a la función buscada; $NN(u) \approx u$, de tal manera que:

$$\begin{aligned} D_t^n (NN[u(\mathbf{x}, t)]) + \mathcal{N} \left[NN[u(\mathbf{x}, t; \lambda)] \right] &= 0, & \mathbf{x} \in \Omega \subset \mathcal{R}^n, \quad t \in [0, T], \\ NN[u(\mathbf{x}, 0)] &= u(\mathbf{x}, 0), & \mathbf{x} \in \Omega \subset \mathcal{R}^n, \\ \mathcal{B}(NN(u(\mathbf{x}, 0))) &, & \mathbf{x} \in \partial\Omega. \end{aligned}$$

image.png

Optimización

La función de costo se construye a partir del problema de minimizar los pesos y los bias de la función aproximada. Y su optimización se presenta a través de restricciones fuertes:

$$\begin{aligned} \min_{\theta} \quad & \mathcal{L}_{ic}(\theta) + \mathcal{L}_{bc}(\theta), \\ \text{s.a.} \quad & \mathcal{L}_f(\theta) = 0. \end{aligned}$$

Bajo restricciones débiles, el problema de minimización se transforma en:

$$\min_{\theta} \quad \mathcal{L}_r(\theta) + \lambda_1 \mathcal{L}_{ic}(\theta) + \lambda_2 \mathcal{L}_{bc}(\theta).$$

El principal problema de optimización es el **desbalance de gradientes** en el método de gradiente descendente.

¿Cuál es el problema que se intenta resolver?

1. Dificultad y mal condicionamiento en la optimización que sufren las redes neuronales informadas por la física.
2. Sensibilidad de la red causada por la elección de las funciones de activación.
3. Elección manual de la función de activación adecuada. Las funciones más usadas para diferentes problemas de las PINNs son: *sinusoidales*, *tangente hiperbólica*, *sigmoide*, *softplus*, *ELU*, *GELU* y *Swish*.

¿Cómo lo hacen?

Proponen un algoritmo ABU-PINN (Adaptative Blending Units for PINNs), es una arquitectura que adopta la búsqueda de funciones de activación mediante de las PINNs mediante la combinación lineal de funciones de activación:

$$f(x) = \sum_{i=1}^N G(\alpha_i) \sigma_i(\beta_i x)$$

Dónde $G(.)$ es la compuerta de activación, $\sigma(.)$ es la función de activación y α_i son los pesos.

¿Cómo lo validaron?

La metodología se validó principalmente en 2 experimentos: El **primer experimento** consistió en comparar el rendimiento de PINNs entrenadas con una sola función de activación bajo simulaciones de dos problemas de PDE de Poisson unidimensional (1D), evaluando el error relativo.




image3.png

El **segundo experimento** consistió en usar un benchmark de EDPs estandarizadas como soluciones de PINNs; se entrenó PINNs con funciones de diferentes funciones de activación clásicas y modernas, con el fin de comparar el rendimiento de las frente a la ABU-PINN.



image4.png

image5.png

¿Qué combinación de funciones mostraron mejor rendimiento?




image6.png

¿Qué compuerta de activación tiene mejor rendimiento?




image7.png

Tiempo de computo

image8.png

Conclusiones

1. Los datos empíricos demuestran que ABU-PINN supera de manera consistente a todas las funciones estándar y métodos adaptativos.
2. En comparación con la mejor función estándar de cada paso, ABU-PINN redujo la tasa de error en un 83 % en la ecuación de convección, un 46 % en KdV y un 56 % en Cahn-Hilliard.
3. El algoritmo adapta su espectro de autovalores directamente a la EDP, obteniendo un autovalor en promedio mucho mayor.
4. el costo es 3.08 veces mayor que una PINN con función de activación tanh.
5. ABU-PINN fracasa ante funciones discontinuas.
6. El modelo asume solamente EDPs de orden superior entera. Los autores esperan evaluar en posteriores trabajos EDPs de orden fraccionaria y EDPs estocásticas.

Referencias

1. Luo, K., Zhao, J., Wang, Y., Li, J., Wen, J., Liang, J., Soekmadji, H., Liao, S. (2025). Physics-informed neural networks for PDE problems: a comprehensive review. Artificial Intelligence Review, 58(323).
<https://doi.org/10.1007/s10462-025-11322-7>
2. Wang, H., Lu, L., Song, S., Huang, G. (2023). Learning specialized activation functions for physics-informed neural networks. arXiv preprint arXiv:2308.04073.